

부록

높은 탐지 성능은 무엇을 측정하는가 — 호스트 행위 기반 악성코드 탐지 평가의 네 층위 분석

부록 A. 사전 명세 문서의 변경 기록

A.1 개요

본 연구는 실험에 앞서 분석 계획을 문서(실험 프로토콜)로 명세했고, 계획을 바꿀 때마다 원래 계획, 실제 처리, 변경 사유, 영향 범위를 기록했다(3.2 절). 프로토콜 최종본(v3.5) 전문은 **보충 자료 S1**로 공개하며, 이 부록은 그중 변경 기록을 옮긴다. 변경 기록은 세 부분으로 되어 있다.

부분	내용	분량
A.3.1 변경 이력 표	각 변경의 발생 조건, 원래 계획, 실제 처리, 변경 이유, 영향 범위, 재현 정보	69 건
A.3.2 버전 이력	프로토콜 판본(v1.0~v3.5)별 변경 요약	25 건
A.3.3 §10.1 정정 상자	개선 발동 기준의 복원 경위	1 건

이 기록은 실험 당시에 작성된 것이므로, 이후 원고를 쓰며 데이터와 원문을 다시 확인해 정정한 해석이나 수치가 옛 모습으로 남아 있다.

A.3 에는 실험 당시 프로토콜이 근거로 언급한 외부 문헌 세 편 — Domingos(2000), Dieterich et al.(2023), Barr-Smith et al. (2021) — 이 원문 그대로 남아 있다. 본 연구의 원고는 이 문헌들을 인용하지 않았고 원문 확인도 거치지 않았으므로 참고문헌 목록에 넣지 않았다.

원문 표의 서식 오류 두 곳은 **서식만** 고쳤다. "2026-09-18 / Phase 1 — 특징 구조" 행은 칸 안의 $|\rho|$ 기호가 칸 구분으로 읽혀 표가 깨지므로 기호를 이스케이프했다. "2026-09-18 / BCCC 데이터셋 접근 승인 기한 도래" 행 끝에는 2026-09-16 "양상블 이론 문헌 조사" 항목의 내용이 줄바꿈 없이 중복으로 붙어 있어 그 부분을 떼었다(해당 항목은 표에 따로 있다). 같은 행의 다섯 번째 칸은 원문에서 문장이 잘려 있으며, 원래 문장을 알 수 없어 그대로 두었다. 또한 기록에서 쓰인 "사전등록"은 공개 저장소에 시점을 남기는 등록이 아니라 연구진 내부의 사전 명세를 뜻한다(3.2 절). 이런 차이는 A.4 의 정정 대조표에 정리했다.

A.2 본문에서 가리킨 변경

본문	변경	기록 위치
3.2 절 첫째	개선 발동 기준의 복원	A.3.2 의 v3.3, A.3.3
3.2 절 둘째	교란 학습 샘플을 학습 분할에서 생성	A.3.1 의 2026-09-21 "교란학습 누수 수정"
3.2 절 셋째	탐색 예산을 개선 속마다 같게	A.3.1 의 2026-09-21 "탐색 예산 조항 폐기", A.3.2 의 v3.4
3.2 절	주실험 데이터셋 교체	A.3.1 의 2026-09-18 "Phase 2 — CIC-MalMem artifact 발견", A.3.2 의 v2.0~v2.6
4.1 절 표 5 각주	프로토콜 §11.3 의 값이 3 값(99.84%)	보충 자료 S1 의 §11.3, A.4

A.3 변경 기록 원문

A.3.1 변경 이력 표 (날짜순, 69 건)

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
2026-09-15 / IDS-ML 환경 구축	로컬에서 IDS-ML 노트북 실행하여 파이프라인 구조 파악	실행 포기 후 .py 변환하여 코드 분석으로 전환	2019 년 코드와 최신 라이브러리 간 버전 충돌 4 건(pandas dtype 2 건, imblearn API 2 건) 발생. 목적이 "실행 결과"가 아닌 "구조 파악"이므로 코드 읽기로 충분	Phase 0 준비 단계에 한정, 실험 결과에 영향 없음	Python 3.13.15, scikit-learn 1.9.1, Windows 11 / nbconvert 사용

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
2026-09-15 / IDS-ML 코드 분석	4.2 절 BO 설정을 "베이지안 최적화, 30 회"로만 기술	BO-TPE(hyperopt) 알고리즘 명시 + RF 탐색공간 구체화 (4.2 절)	IDS-ML 에서 검증된 탐색 범위를 채택하여 임의 설정을 줄임	4.2 절, Phase 3 이후 모델 B·C	hyperopt TPE, max_evals=30
2026-09-15 / IDS-ML 코드 분석	(해당 없음 — 신규 기록)	4.2.1 절 신설: 선행 구현 대비 의도적 상이점 3 건 문서화	선행 연구에서 데이터 누수 패턴 2 건(스태킹 in-sample 예측, BO 목적함수에 Test 사용) 발견. 본 프로토콜이 이를 이미 방지하고 있음을 확인하고 근거로 기록	4.2.1 절, 논문 방법론 서술	Tree-based_IDS_GlobeCom19.py L320-327, MTH_IDS_IoTJ.py L453-455
2026-09-16 / 앙상블 이론 문헌 조사	(해당 없음 — 범위 유지 결정)	편향-분산 분해(Domingos 2000)를 이론 인용 및 결과 해석 근거로만 사용, 실측은 수행하지 않음	0-1 손실에 직접 적용 가능한 분해 이론을 확보했으나, 실측 추가 시 사전등록 시점의 실험 범위를 벗어남. 범위 유지를 우선	논문 2 장·결과 해석 서술. 실험 절차 변경 없음	Domingos(2000) AAAI/ICML / mlxtend bias_variance_decomp 미사용
2026-09-18 / Phase 2 — CIC-MalMem artifact 발견	CIC-MalMem-2022 를 주실험 데이터셋으로 사용 (11.1 절 2 순위)	주실험을 DMBD 2025 로 대체. CIC-MalMem 은 11.3 절 artifact 사례연구로만 사용	깊이 1 결정트리 가 99.65% 달성. svcscan.nservices 가 정상 395/악성 389 로 거의 결정적 분리 → 악성 행위가 아닌 VM 환경 상태를 학습. 이 데이터로는 4 축 진단이 전부 artifact 탐지에 관한 것이 됨	11 장 전체, 2.1·3.2·3.3.2·4.3·5·6.3·8·13 장	DMBD 깊이 1 76.33% vs CIC-MalMem 99.65%
2026-09-18 / Phase 2 — 분석 단위 복원	1 행(메모리 덤프) = 1 샘플 (v2.5)	1 실험(experiment) = 1 샘플로 복원	DMBD 는 experiment 필드가 정상·악성 양쪽에 존재하여 대칭 적용 가능. v2.5 의 강등은 CIC-MalMem 의 구조적 결함에 대응한 것이었음	3.2·2.1·3.4 절	64,747 실험
2026-09-18 / Phase 2 — H4 재정의	교차 데이터셋 재현(CIC-MalMem → DMBD)	코호트 간 재현으로 재정의 (DMBD 2017 vs 2024)	CIC-MalMem 이 사례연구로 전환되며 유효한 두 번째 데이터셋 소멸. artifact 지배 데이터셋의 결과는 재현 여부 해석 불가	H4, 1.2·11.2 절	cross-dataset 미수행을 한계로 명시
2026-09-18 / Phase 2 — 공식 분할 교란	공식 train/test 분할 보존	보존 유지 + 코호트별 분리 보고 의무 신설	test 정상은 100% 2024 년, test 악성은 87.8%가 2017 년으로 연도-라벨 교란 존재. 분할 변경 없이 교란 크기를 노출시키는 방법 선택	11.2.1·8 장	추가 실험 비용 없음
2026-09-18 / Phase 2 — 발생률 정규화 폐기	분당 발생률(events/min)로 정규화	원시 카운트 사용, duration_s 는 별도 특징으로 유지	duration_s 중앙값 1.36 초, p10 0.04 초, 0 이하 401 건으로 나눴셈이 불안정. 명목 관측 창이 5 분으로 동일하므로 원시 카운트가 이미 비교 가능	3.3.2·1A.2 절	공식 베이스라인도 원시 카운트 사용
2026-09-18 / Phase 2 — 난이도 분류 재작성	가상의 발생률 특징 기준 난이도표	실제 14 개 특징 기준으로 전면 재작성 (쉬움 9 / 어려움 4 / 제외 1)	v2.5 난이도표가 실제 특징과 불일치. 6.2 절 판정 기준은 불변, 대상만 교체	6.3·6.4 절, H2 (n=9)	n_events 는 파생합이라 교란 제외
2026-09-18 / Phase 2 — MIA·불균형 조건 재판정	MIA 옵션 A, 불균형 미적용 (CIC-MalMem 기준)	MIA 옵션 B 로 전환(family 구조 부재, 연도 분포로 매칭), Class Weight 적용	데이터셋 교체로 사전 조건문 재평가. 결과를 보고 고른 것이 아님	4.3·5.1·5.3 절	shadow-model 1 순위 유지

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
		(소수 39.0% < 40%)			
2026-09-18 / Phase 2 — family 평가 불가	미지 family 탐지를 기본 설정으로	시간적 일반화(코호트 간) 평가로 대체	DMBD 는 malware family 라벨을 제공하지 않음	2.1·11.2 절	한계로 명시
2026-09-18 / Phase 1 — 정상 샘플 실행 ID 부재	3.2 절 "1 실행 = 1 샘플", 3.3 절 스냅샷 집계, 3.3.1 절 감염시점 이중설정	3.2 절 재확장: 1 행(메모리 덤프) = 1 샘플. 3.3·3.3.1 절 폐기. 3.2.1 절 신설(복원 불가 검정 근거)	정상 29,298 행의 Filename 이 전부 "Benign"으로 실행 ID 부재. 악성만 집계하면 std=0 이 정상을 완벽 판별하는 치명적 누수 발생. 파일순서 기반 복원도 검정으로 불가 확인(인접행 거리 악성 0.268 vs 정상 0.782, 10 주기 구조 없음)	3.2·3.2.1·3.3·3.3.1·3.4 절, 2.1 절, 6.4 절 n 산정	MalMem2022.csv, 58,596 행×58 열
2026-09-18 / Phase 1 — 분할 설계	family 비중복 그룹 분할(대칭)	2.1 절 비대칭 그룹 분할 — 악성은 실행+family 단위, 정상은 행 단위 무작위	정상에 그룹 구조가 없어 대칭 적용 불가. 악성만이라도 실행 단위 분할로 누수 차단	2.1 절, 4.2.1 절	악성 2,906 실행 / 15 family(141~229 실행)
2026-09-18 / Phase 1 — 특징 구조	3.3 절 "집계 후 30 개 초과 시 중복 제거"	3.3.2 절로 이관, 원 특징 55 개 기준 적용. 상수 3 개 사전 제거	집계 폐기로 기준이 무의미해졌으나 원 특징에 강한 중복 존재(p >0.95 쌍 40 개, 일부 p=1.000)	3.3.2 절, 3.4 절	Spearman, 컬럼순서 후자 제거
2026-09-18 / Phase 1 — 불균형·MIA 조건 확정	조건부 규칙(4.3 절 40% 기준, 5.1 절 30% 기준, 5.3 절 100 기준)	불균형 처리 미적용(50:50 균형), MIA 옵션 A 적용(15 family 전부 조건 충족), shadow-model 1 순위 적용 (그룹 수 2,906/29,298)	사전 정의된 조건문을 데이터에 적용한 결과	4.3·5.1·5.3 절	결과를 보고 고른 것이 아니라 조건문 실행
2026-09-18 / Phase 1 — 난이도 분류 불일치	6.2~6.3 절 난이도표가 "분당 발생률" 특징 전체	Phase 2 에서 실제 55 개 특징 대상으로 전면 재작성 예정으로 표기. 판정 기준·규칙은 불변	실제 특징은 VolMemLyzer 정적 카운트 지표(pslist/handles/psxview 등). 네트워크로 상정했던 handles.nport 는 상수	6.2·6.3·6.4 절, H2	미해결 항목
2026-09-18 / 2 차 검토 ① H5 방향	모든 축에 "CI 하한 $\geq -\delta$ " 단일 부등식 적용	지표 방향별로 부등식 분리 — 높을수록 좋은 지표 (MCC)는 CI 하한 $\geq -\delta$, 낮을수록 좋은 지표 (AUC_adv/flip/latency)는 CI 상한 $\leq +\delta$	방향을 무시하면 판정이 뒤집힘. MIA AUC 가 낮아지는 것이 개선인데 하한 기준을 적용하면 오판	10.4 절 (a)(b) 전체	방향 규정표 추가
2026-09-18 / 2 차 검토 ② MIA 방향	MIA AUC 원시값 사용	5.4 절 신설 — AUC_adv = max(AUC, 1-AUC) 도입, 8 장·10.1·10.4·1.2 절에 일괄 적용	AUC 0.40 은 공격자가 판정을 뒤집으면 0.60 이 되므로 "더 안전"이 아님. 0.5로부터의 거리가 실질 공격 가능성	5.4 절, 8 장, 10.1 절, 10.4 절, 1.2 절	원시 AUC 병기 의무
2026-09-18 / 2 차 검토 ③ 판정불가 규칙	"CI 폭 > 2δ → 판정 불가"	규칙 폐기. CI 가 ±δ 경계를 가로지르는지로 3 분 판정 (비열등/열등/판정불가)	CI 가 넓어도 판정 가능한 경우가 있음. 예: δ=0.05, CI [0.10,0.50]은 폭 0.40 이지만 하한 0.10 > -0.05 로 비열등 확립	10.4 절	수학적 오류 수정
2026-09-18 / 2 차 검토 ④ Phase 6 출발점	선택적/일괄 개선의 출발 모델 미명시	10.3 절 — 출발 모델을 Model A 로 고정, 다이어그램 추가. B·C·D 는 Phase 6 미진입	출발 모델이 다르면 관측 차이가 개선 전략 때문인지 모델 때문인지 분리 불가	10.3 절, 12 장	H5 는 "전략의 차이"를 묻는 가설

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
2026-09-18 / 2 차 검토 ⑤ H2 분석단위	분석 단위 미명시, 기울기 부호 모호	6.4 절 — 분석 단위를 최종 입력 특징 컬럼($n \approx 12$)으로 고정, $S_i =$ $-\Delta p / \Delta \text{reduction}$ 부호 정의	기저 행위 단위면 "쉬움" 3 종뿐이라 $n=3$ 으로 상관 분석 불가. 부호 미정의 시 상관 방향 해석 불가	6.4 절, H2 가설행	최종 n 보고 의무, 경향 관찰로 서술
2026-09-18 / 2 차 검토 ⑥ BCCC 잔재	H4·1A.1·1A.2·12 장에 BCCC 가 현재 절차로 남아 있음	현재 절차 문장을 CIC- MalMem-2022 기준으로 통일. BCCC 는 14 장 변경이력에만 역사적 기록으로 유지	11.1 절에서 데이터셋이 전환되었으나 본문 일부가 갱신되지 않았음	H4 가설행, 1A.1, 1A.2, 12 장	—
2026-09-18 / 2 차 검토 ⑦ nested CV 용어	"Train 내부 중첩 교차검증 (nested CV)"	"Train 내부 3-fold 교차검증"으로 표현 수정, nested CV 가 아님을 명기	nested CV 는 inner/outer 이중 CV 구조를 뜻함. 본 설계는 Train 내부 CV + 별도 Validation/Test 의 hold-out 구조	2.3 절, 4.2 절	용어 정확성
2026-09-18 / 2 차 검토 ⑧ 비용 표현	MCC·Youden's J·0.5 를 "등가중 비용 가정 공유"로 묶어 서술	세 요소의 성격용 표로 분리. 0.5 는 스트레스테스트 기준점, Youden's J 는 대칭적 취급 (비용비는 유병률 의존), MCC 는 균형 반영 지표로 규정	0.5 임계값 자체가 FP/FN 등가 비용을 의미하지는 않음. Youden's J 도 Smits 지적대로 암묵 비용비가 유병률에 의존	8 장, 1A.4 절 연결	"비용 최적 임계값"이라는 서술 금지
2026-09-18 / 2 차 검토 ⑨ 12 장 B·C 규칙	"B·C 와 A 의 차이 CI 가 0 을 포함 → Phase 6 생략"	Phase 6 진입 여부와 무관함을 명시하고 규칙의 목적은 탐지 성능 서술로 한정	탐지 성능 차이 유무와 MIA/강건성/리소스 진단 기반 개선은 논리적으로 연결되지 않음. ④ 결정으로 B·C 는 애초에 Phase 6 미진입	12 장	—
2026-09-18 / 외부 검토 반영 ① H5	10.2 절이 "개선 전후" 차이를 판정 (H5 는 " 선택적 vs 일괄"을 주장)	10.4 절 신설 — 목표측 비열등성 + 부작용측 우위의 이중 검정 구조, δ 사전 고정, 검정력 부족 시 판정불가 규칙	검정 단위와 가설이 어긋나 있었음. H5 를 직접 검정하는 규칙 부재	10.4 절, H5 가설표	δ : MCC 0.05 / MIA AUC 0.02 / flip 5%p / latency 20%
2026-09-18 / 외부 검토 반영 ② MCC 기준	MCC "20% 상대 개선" (v2.1 에서 도입)	절대 차이 $\Delta \text{MCC} \geq 0.05$ 로 변경. MIA AUC 는 초과분 20% 상대 감소 유지	MCC 는 [-1,1] 상관계수라 상대 변화율이 불안정 (0.05 → 0.10 이 100%). 10.2 절 허용한도(절대 0.05)-10.4 절 δ 와 내부 불일치도 존재했음	8 장, 10.2 절	축별 기준 상이 사유를 8 장에 명기
2026-09-18 / 외부 검토 반영 ③ 감염시점	감염시점 라벨 존재 시 감염 후 구간만 집계	3.3.1 절 신설 — 설정 A(전체 스냅샷, 주)와 설정 B(감염 후, 보조) 병행. H1~H5 는 A 에서만 검정, A/B 비교는 탐색적	실제 배포 시 감염 시점을 알 수 없으므로, 감염 후 구간만 쓰면 1A.2 절의 " 실행 후 수 분 내 탐지" 정당화와 충돌	3.3 절, 3.3.1 절, Phase 3~4 실험량 증가	설정 B 는 Phase 3~4 까지만, Phase 6 미적용
2026-09-18 / 외부 검토 반영 ④ RF 기준값	"n_estimators 기본 300"	"본 연구 고정 기준값 300"으로 표현 변경 및 선정 사유 명기	scikit-learn 1.9.1 의 라이브러리 기본값은 100 이므로, "기본 300"은 오해를 유발	4.2 절	숫자 300 자체는 유지
2026-09-18 / 외부 검토 반영 ⑤ MIA target	target model 과 탐지 모델 A/B/C/D 의 관계 미명시	5.0 절 신설 — target 은 A/B/C/D 를 MIA 전용 분할로 재학습한 인스턴스. 하이퍼파라미터 재탐색 금지	미명시 시 Phase 3 탐지 성능표의 모델을 공격한 것으로 오해 가능. H3 검증에는 모델 4 종 각각 공격이 필요	5.0 절, Phase 4 MIA	Phase 3 확정 하이퍼파라미터 재사용

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
2026-09-18 / 외부 검토 반영 ⑦ H1	H1 을 가설로 두고 "축별 지표 간 상관관계 보고"	1.1 절 신설 — H1 을 확증적 가설에서 제외. 상관계수·유의성 검정 미수행, 4 종 병렬표 + 반례 존재 여부로 판정	모델 4 종이므로 n=4 상관은 해석 불가. 시드 반복을 표본으로 환산하면 유사반복. H1 은 부정 명제이므로 반례 하나로 판정 가능	1.1 절, H1 가설행, 8 장 보정 대상	다중비교 보정 대상에서 제외
2026-09-18 / 외부 검토 반영 ⑧ 특징중요도	permutation importance 산출 데이터·지표·반복 미명시	6.4 절 신설 — Validation / scoring=MCC / n_repeats=10. 교란 실험도 동일 Validation 집합. MDI·TreeSHAP 미사용	H2 는 중요도와 교란 반응의 상관을 보므로 동일 데이터·동일 특징 집합에서 산출되어야 성립. Test 는 9 장 보호 대상	6.4 절, H2 가설행	TreeSHAP 은 모델 간 공정 비교를 해쳐 배제
2026-09-18 / 외부 검토 반영 ⑩ 불균형	"Class Weight → Under → Over 순" (누적/택일 모호)	4.3 절 재작성 — 택일임을 명시, 조건별 전환 규칙 및 "처리하지 않음" 행 추가	순차 누적으로 읽힐 수 있었음. Under 와 Over 동시 적용은 상쇄·왜곡을 유발	4.3 절	CIC-MalMem-2022 는 완전 균형이라 미적용 예상
2026-09-18 / 외부 검토 반영 ⑫ 중복제거	" r > 0.95" (Pearson/Spearman 미명시, 제거 대상·시점 미정)	Spearman(p >0.95), 컬럼 순서상 후자 제거, 분할 직후·스케일링 직전 수행으로 구체화	발생률 기반 특징은 왜도·이상치가 커 Pearson 이 부적합. 임의 선택 시 재현 불가	3.3 절, 3.4 절	H2 의 Spearman 과 일관
2026-09-18 / 외부 검토 반영 ⑨ 스택킹 상관	(신규 제안: 베이스 모델 예측 상관 측정 추가)	추가하지 않음	다양성 지표와 양상불 성능의 관계가 이론적으로 확립되지 않아(Kuncheva & Whitaker 2003) 측정해도 해석이 어려움. 실험 범위 유지 우선	변경 없음	—
2026-09-18 / 비용 가중 검토	(해당 없음 — 암묵적 등가중 가정이 명시되지 않은 상태)	1A.4 절 신설(비용 민감도 평가 미수행을 명시적 한계로 선언) + 8 장에 등가중 가정 선언 추가	MCC·Youden's J·임계값 0.5 에 오탐/미탐 등가중 가정이 공통으로 깔려 있으나 명시되지 않았음. 비용비를 정할 근거가 없어 비용 가중 도입 대신 가정을 명시하고 한계로 기록하는 방향 선택	8 장, 1A.4 절, 논문 한계점·향후과제 서술. 실험 절차 변경 없음	등가중 가정 유지, 비용 민감도 평가 미수행
2026-09-18 / 이진분류 판정기준 문헌 검토	주평가지표 F1-score (8 장)	주지표를 MCC 로 교체. F1·Precision-Recall·PR-AUC·혼동행렬은 기술적 보고로 병기(가설검정 대상 아님). 8.1 절 신설(혼동행렬 제시 규칙)	F1 은 진음성(TN)을 계산에 포함하지 않아, 오탐률을 핵심 관심사로 삼는 본 연구의 의사결정 지표로 부적합(Chicco & Jurman 2020). Phase 1 착수 전이므로 사전등록 원칙 위반 아님	8 장, 4.2 절 BO 목적함수, 10.2 절 허용한도, 12 장 미수렴 기준, 13A 절 스윙 지표, H1·H4 서술	Chicco & Jurman(2020) BMC Genomics 21:6 / 반론: Holzmann & Klar
2026-09-18 / BCCC 데이터셋 접근 승인 기한 도래	주실험 데이터셋으로 BCCC-MalMem-SnapLog-2025 또는 BCCC-Mal-NetMem-2025 사용 (11.1 절 1 순위)	CIC-MalMem-2022 로 자동 전환 (11.1 절 2 순위 적용)	11.1 절에 사전 정의된 기한 (2026-09-18)까지 BCCC 측 승인 회신이 없었음. 실험 결과와 무관한 접근성 사유이며, 사전 조건문 실행에 해당	주실험 전체(Phase 1~6). 교차검증 데이터셋(DMBD 2025)은 변경 없음. 논문에 2022 년 수집 데이터임을 명시하고 "최신 악성코드 동향 반영" 주장 금지 (원문에서 문장이 끊겨 있음)	CIC-MalMem-2022 (Carrier et al., ICISSP 2022), 58,596 레코드, VolMemLyzer 55 개 특징
2026-09-19 / H5 평가 무대 재설계	H5 최종 판정을 공식 Test 에서 수행	H5-Test 신설 — 공식 train 을 Train 60% / Validation 20% / H5-Test 20%로 3 분할. H5 판정은 H5-Test	공식 Test 는 연도·라벨 교란(11.2.1 절)과 사전확률 이동(11.2.2 절)의 이중 오염으로, 관측된 차이가	2.1·8·9·10.3·10.4·11.2.1·13 장. Phase 3 재실행 필요 (Train 30,000 ~ 24,000)	H5-Test 는 50:50 균형·연도 혼합으로 두 오염 모두 없음

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
		에서만, 공식 Test 는 시간적 일반화 보고 전용으로 용도 한정	개선 전략의 효과인지 분리 불가. Validation 재사용은 선택-검증 미분리로 낙관적 편향 발생. 따라서 선택용과 최종판정용을 분리		
2026-09-19 / 9 장 개정	"Phase 6 Test Set 및 MIA 평가셋 보호 원칙"	평가셋 4 종의 보호 수준·사용 시점을 표로 명시하고 "선택과 검증의 분리" 원칙을 명문화	H5-Test 신설로 평가셋이 4 종이 되어 각각의 용도와 봉인 수준을 구분할 필요 발생	9 장	Validation=선택, H5-Test=검증
2026-09-19 / Phase 3 — BO 알고리즘 대체	hyperopt 의 BO-TPE (4.2 절)	GP 기반 BO(Matérn 2.5 + Expected Improvement) 직접 구현으로 대체. 탐색 공간·시행 횟수(30 회)·목적함수는 불변	실행 환경에 hyperopt 미설치이며 네트워크 차단으로 설치 불가. GP-EI 는 Frazier(2018) 튜토리얼이 설명하는 표준 BO 형태이며, TPE 채택 사유였던 "IDS-ML 탐색 공간"은 그대로 유지됨	4.2 절, 모델 B·C	초기 무작위 10 + BO 20, 최적 CV MCC=0.8360
2026-09-19 / Phase 3 — Class Weight 판정 정정	소수 클래스 39.0% < 40% → Class Weight 적용 (v2.6)	미적용으로 정정	전체 데이터 기준으로 판정한 오류. 클래스 가중은 학습 시 적용되므로 Train 분포로 판정해야 하며, 공식 train 은 정확히 50:50	4.3 절, Phase 3 이후 전체	Train 20,000/20,000
2026-09-19 / Phase 3 — MLP 설정 확정	은닉층 1~2 개, 유닛 [16,128] (탐색 주체 불명확)	미튜닝 + scikit-learn 기본값 (100,) 고정	A(미튜닝 RF)와 D 의 대칭성 확보. 임의값 (64,) 대신 라이브러리 기본값을 근거로 삼아 선택 자의성 제거	4.2 절, 모델 D, H3 해석	재실행 결과 MCC 0.6309
2026-09-19 / Phase 3 — 스택킹 베이스 교체	Gradient Boosting 1 종	HistGradientBoosting 으로 대체	연산 시간 제약(OOF 5-fold × 5 시드). 동일 알고리즘 계열의 고속 구현이며 성능 특성 유사	4.2 절, 모델 C	시드당 약 42 초
2026-09-19 / Phase 3 — max_features 상한 확정	[1, 20]	[1, 12]	중복 제거 후 최종 특징 수가 12 개이므로 상한을 실제 차원에 맞춤	4.2 절	—
2026-09-19 / Phase 3 — H2 분석 단위 축소	교란 대상 "쉬움" 9 개 (n=9)	중복 제거로 2 개 탈락, n=7	Train 에서 n_events~n_uniq_cguid $\rho=1.000$, ~n_uniq_child $\rho=0.983$. 결론론적 규칙에 따라 교란 대상 2 개가 탈락하고 교란 제외 항목 (n_events)이 잔존	6.3·6.4 절, H2 검증력	규칙을 사후 변경하지 않음, 한계로 기록
2026-09-19 / Phase 3 — 사전확률 이동 발견	(해당 없음 — 신규 발견)	11.2.2 절 신설	공식 train 은 50:50 이나 test 는 악성 78.8%. 연도 교란과 별개의 문제로, 임계값 이식·PR-AUC 비교에 직접 영향	11.2.2·8·9 장, Phase 6	Test 재조정 금지 원칙 유지
2026-09-20 / 간접 교란 검증	§11.2.3 에서 "연도 상관 행위특징 가능성"을 한계로만 기록	§11.2.4 신설 — 직접 측정 및 영향 크기 정량화	한계를 서술로만 남기면 크기를 알 수 없음. 측정 결과 행위특징이 연도를 직접 함유($R^2=0.639$, 라벨 고정 시에도 악성내부 $R^2=0.578$)하나, 연도단독 AUC 를 0.5 로 만든	§11.2.4, Phase 3~4 결과 해석, Phase 6 개선효과 서술	교란 기여 약 0.03 MCC (허용한도 0.05 의 60%)

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
			조건에서도 MCC 0.7788 유지		
2026-09-20 / Phase 5 — H4 폐기	DMBD 연도 코호트 간 재현(2017 vs 2024)으로 H4 검증	H4 폐기. 재현 검증을 수행하지 않으며 폐기 근거를 결과로 보고 (§11.2.3)	Train+Val 의 2024 코호트에 약성 0 건으로 분류 불가. 대안 코호트 (2017 vs 2020-2022)는 2017 측이 2,000 건으로 제한되어 MIA 감사셋이 500 건 수준까지 축소, 검정력 부족. 불균형 수용은 사전확률 91.7% vs 53.3% 로 새 교란 도입. 무작위 분할은 독립 재현이 아님	H4, 1.2·11.2·11.2.3·12·13 장, 8 장 다중비교 대상	확증적 가설이 H2·H3·H5 3 개로 축소
2026-09-20 / Phase 5 — 교란 범위 재인식	연도-라벨 교란을 공식 test 분할의 문제로 한정 (§11.2.1)	데이터셋 전면의 문제로 확대 기록 (§11.2.3)	연도만으로 라벨 예측 시 ROC-AUC: 전체 0.9070 / Train+Val 0.9119 / 공식 Test 0.9391. 약성은 2017 년 집중, 정상은 2023~2024 년 집중	§11.2.3, 한계 서술	year 는 특징에서 제외되어 있으나 연도 상관 행위특징 가능성은 한계로 명시
2026-09-20 / Phase 4 — 리소스 기준배치 확정	§10.1 "샘플당 지연시간 > 1ms" (기준 배치 미지정)	batch=10 기준으로 고정	동일 모델이 배치 크기에 따라 조건 충족 여부가 달라짐(모델 A: batch=10 에서 1.2209ms 충족, batch=1000 에서 0.0441ms 미충족). 기준 미고정 시 사후에 유리한 배치 선택 여지 발생. §1A.2 실시간 에이전트 맥락에 부합	§10.1, Phase 6 리소스 개선 발동	세 배치 모두 보고하되 판정은 batch=10
2026-09-20 / Phase 4 — MIA 결과	(진단 수행)	A 0.5720 / B 0.5259 / C 0.5230 유출 검출, D 0.5001 미검출 (AUC_adv, 감사셋 n=3998)	과적합 격차 순서(A 0.153 > B 0.071 > D 0.008)와 MIA 취약성 순서가 일치. D 는 95% CI 가 0.5 를 포함	Phase 6 프라이버시 개선 대상 판정	shadow model 5 개, 연도 분포 매칭 완료. TPR@1%FPR 0.010~0.017
2026-09-20 / Phase 4 — H2 결과	(가설 검정)	네 모델 모두 양의 상관($\rho = +0.536 \sim +0.893$). D 만 $p < 0.05$	n=7 로 검정력 부족. §6.4 규칙대로 "경향 관찰"로 서술	H2 서술	A $\rho = 0.750(p = 0.052)$, B·C $\rho = 0.536(p = 0.215)$, D $\rho = 0.893(p = 0.007)$
2026-09-20 / Phase 4 — 교란 민감도 결과	(진단 수행)	최대 flip rate 6.45% (file_create 30% 감소, 모델 A). 무효 변형 0 건	조작 용이 특징만으로는 회피가 어려움. §6.2 유효성 기준(비음수·Train 범위·n_events 정합성) 전부 통과	Phase 6 강건성 개선 대상 판정	net_connect 는 중요도 1 위임에도 flip rate 0 (13.1 절 기록)
2026-09-20 / Phase 3 재실행 — 분할 변경 반영	Train 30,000 / Val 10,000 (v2.7 분할)	Train 24,000 / Val 8,000 / H5-Test 8,000(봉인)로 재실행. BO 재탐색 포함 전 과정 재수행	v2.8 의 H5-Test 신설에 따른 필수 재실행. 기존 결과는 old_run/에 보존	Phase 3 전체 결과, 4.2 절 BO 최적값	봉인 해시 기록: H5-Test 47254fd15bb1f192, 공식 Test c63d8ca03e7a4480
2026-09-20 / Phase 3 — 스테킹 판정 변경	B → C 차이 CI [-0.0036, -0.0003] → "하락 확정" (구 분할)	CI [-0.0045, +0.0011] → "유의미한 차이 발견 못함"	효과 크기는 유사(-0.0020 → -0.0017)하나 Validation 이 10,000 → 8,000 으로 줄어 CI 가 넓어짐. 12 장 규칙에 따라 판정 유보	H3 해석, 12 장	효과 크기 변화가 아닌 검정력 변화
2026-09-20 / Phase 3 — 모델 C 임계값 불안정	Youden's J 조정 가능 (구 분할, 폭 0.082)	0.5 고정으로 회귀 (폭 0.262 > 0.2)	8 장 사전 규칙(부트스트랩 CI 폭 > 0.2 이면 불안정)에 해당. 스테킹 메타모델 출력	8 장, 모델 C 평가	A·B·D 는 안정(폭 0.067~0.110)

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
			분포로 인해 Youden 최적점이 흔들림		
2026-09-21 / Phase 6 — H5 판정	(가설 검정)	H5 기각	§10.4 규칙 적용 결과 목표축(지연) 비열등, MCC 우위이나 MIA 축 열등(CI 하한 0.0330 > δ 0.02). 지지 조건 불충족	H5, 10A.1	사전등록 규칙 그대로 적용, 사후 재해석으로 판정 변경하지 않음
2026-09-21 / Phase 6 — H5 설계 문제 식별	H5 부작용축에 프라이버시·강건성 포함	판정 불변, 10A.2 에 교훈으로 기록	일괄 개선이 해당 축을 의도적으로 개선하므로 우세가 설계상 예정됨. 또한 A 의 두 축은 §10.1 기준상 이미 문제없음	10A.2, 논의·한계 서술	결과를 본 뒤 식별한 문제이므로 판정 근거로 쓰지 않음
2026-09-21 / Phase 6 — 교란학습 설계 결함	§10.3A ㉓ 교란학습 (악성만 증강)	한계로 기록(10A.3)	악성만 증강하여 학습 데이터 사전확률이 50% → 58.3%로 이동. 2024 코호트에서 탐지율 차이 +0.0626 대비 AUC 차이 +0.0045 에 불과, 악성 확률 동일하고 정상만 악성 쪽 이동 확인	10A.3, 일괄 개선 수치 해석	향후 정상 샘플 동비율 증강 또는 클래스 가중 보정 필요
2026-09-21 / Phase 6 — 공식 Test 보고	(시간적 일반화 보고)	코호트별 분리 보고 완료 (10A.4)	전 모델 공통으로 2024 악성 탐지율이 2017 대비 0.06~0.13 하락. 2024 코호트 내부 AUC 를 병기해 구분 능력과 판단 경계를 분리	10A.4	H5 판정에 미사용(§9)
2026-09-21 / Phase 6 — B 해석 정정	"BO 가 분포 밖 일반화를 희생" (최초 해석)	"BO 가 보수적 판단 경계를 형성"으로 정정(13.2)	2024 AUC 0.9252 로 RF 계열 중간 수준. 낮은 탐지율은 보수적 보정(악성 평균확률 최저 0.7139, FPR 최저 0.0703)에 기인	13.2, 논의 서술	탐지율 기반 해석의 한계를 보여주는 사례로 논의에 포함
2026-09-21 / Phase 6 실행 명세 확정	구현 세부 다수 미정의	§10.3A 신설 — H5-Test 봉인 해제 전 7개 항목 고정	봉인 해제 후에는 변경 불가하므로 사전 확정 필요	§4.2, §10.3A, Phase 6 전체	아래 개별 항목 참조
2026-09-21 / 탐색 예산 조항 폐기	§4.2 "선택적 개선과 총 탐색예산 동일"	축별 10 회로 변경, 해당 조항 폐기	총량 맞춘은 일괄 개선을 덜 튜닝시켜 H5 지지 방향으로 편향. 원래 목적 (Validation 과적합 방지)은 v2.8 H5-Test 신설로 이미 달성	§4.2, §10.3A ㉔	경량화는 두 경로가 공유
2026-09-21 / 교란학습 누수 수정	§4.2 "6 장(Validation)에서 생성한 교란 샘플 증강"	Train 악성 샘플에서 새로 생성	Validation 변형본이 학습에 들어간 모델을 Validation 으로 평가하면 강건성 과대평가. 해석 문제가 아닌 명백한 버그	§4.2, §10.3A ㉕	부족 시 복원 추출
2026-09-21 / 정규화 파라미터 변경	정규화 강도 3 단계 (파라미터 미지정, 논의 중 max_depth 제한)	min_samples_leaf ∈ {2,5,10}	모델 A 리프의 48.3%가 단일 샘플(암기의 실제). min_samples_leaf 는 이를 직접 차단. 구조 진단에서 도출했으며 성능 결과를 보고 고른 것이 아님	§4.2, §10.3A ㉖	max_depth=5 는 자연깊이 (38) 대비 과도
2026-09-21 / 리소스 개선 성공	§8 에 지연시간 축의 개선 성공 기준 미정의	batch=10 기준 20% 이상 상대 감소로 정의	§10.1 의 1ms 는 실무 요건이 아니라 상대 비교용	§8, §10.2, Phase 6	발동 기준(1ms)은 사후 조정 방지를 위해 불변

발생 조건	원래 계획	실제 처리	변경 이유	영향 범위	재현 정보(seed/버전/파라미터)
기준 확정			설정값임이 §7.1 (4)에서 확인됨(업계 환산 시 네 모델 모두 CPU 1% 미만). 절대 기준을 성공 판정에도 쓰면 자의성이 결론까지 전파. 상대 기준은 MIA AUC_adv 20%와 형식도 통일		
2026-09-21 / 상시 구동 관점 확장 측정	§7 은 추론 1 회 비용만 측정	§7.1 신설 — 메모리·꼬리지연·집계비용 측정 및 업계 실측치 대조	상시 구동 에이전트 관점에서 추론 지연만으로는 자원 비용을 대표할 수 없음	§7.1, 결과 해석·한계 서술	탐색적 부가 분석, §10.1 판정에 미사용. 집계비용이 하한으로 작용(B 는 총비용의 60%, D 는 98%)

A.3.2 버전 이력

- v1.0~v1.1: 최초 프로토콜, 클래스불균형·중단기준 신설
- v1.2: 연구범위 축소, 그룹기반분할, MIA 축제외규칙 폐기, 용어수정, 모델 4 종 세분화, H5 규칙 신설, DMBD 공식분할 보존
- v1.3: (1) MIA 평가셋 독립 분할 재설계(옵션 A/B 조건부 전환) (2) CI 비교를 "개별 CI 중첩"에서 "차이의 CI"로 전면 수정 (3) 교란 유효성 기준을 검증가능/불가능으로 분리 (4) 4.2 절 신설, 하이퍼파라미터·탐색범위 구체화 (5) 임계값 용도 분리 (6) H4 축별 재현판정 분리 (7) H5 "20%개선"을 무작위기준 초과분 대비로 정의 (8) H3 표현 하향("순수 구조효과" → "파이프라인 차이") (9) 14 장 변경이력표 복원
- v1.4: 11.1 절 신설 — 주실험 데이터셋 전환 규칙을 접근성 기반 사전 결정 형태로 명문화 (2026-09-18 기한, 미승인 시 CIC-MalMem-2022 로 자동 전환). 대체 데이터셋의 프로토콜 적합성(family 라벨·샘플당 복수 덤프·다중 스냅샷 구조) 사전 확인 결과 및 최신성 한계 명시 의무 포함
- v1.5 (2026-09-15): IDS-ML 코드 분석 결과 반영 — (1) 4.2 절 BO 항목에 BO-TPE(hyperopt) 알고리즘 명시 및 RF 탐색공간 구체화 (2) 4.2.1 절 신설: 선행 구현 대비 의도적 상이점 3 건(OOF 스테킹, BO 목적함수, 그룹 분할) 문서화 (3) 14 장 변경이력에 당일 작업 3 건 기록
- v1.6 (2026-09-15): 데이터 가공 파이프라인 확정 — (1) 3.2 절 신설: 분석 단위를 "1 회 실행 = 1 샘플"로 확정(스냅샷 개별 취급 금지), 표본 감소 대가와 한계 명시 의무 포함 (2) 3.3 절 신설: 스냅샷 집계 방식을 감염시점 라벨 유무에 따른 조건부 자동결정 규칙으로 사전등록(통계요약 = 평균·최대·표준편차·기울기) (3) 3.4 절 신설: 누수 방지 처리 순서 명문화(분할이 스케일링·불균형처리보다 선행) (4) 4.2.1 절에 IDS-ML 전처리 순서 상이점 추가 (5) 13 장 Phase 1 확정항목에 집계 관련 3 건 추가
- v1.7 (2026-09-15): 1A 절 신설 — (1) 본 연구가 침입 탐지가 아니라 "실행 중 악성 행위 탐지"임을 명시하고 IDS 용어 사용을 금지 (2) 관측 창(수 분)이 breakout time 29 분·TTE 43 분 등 실제 위협 시간 척도와 부합함을 근거로 정리, 7 장 리소스 진단의 중요성과 연결 (3) "저활동 잠복형 악성코드는 탐지 대상에서 사실상 제외"를 구조적 한계로 명시하고 결과 해석·보고 의무 규정, 파일 이벤트율 특징의 판별력 제한 가능성을 Phase 4 확인 항목으로 연결
- v1.8 (2026-09-15): 근거 문헌 검증 결과 반영 — (1) 6.3 절 레지스트리 난이도의 "권한 불필요" 항목을 X → O 로 정정(HKCU Run 키는 사용자 권한만으로 조작 가능, Dieterich et al. ICISSP 2023 실험 근거). 분류 결과는 쉬움으로 불변, 근거 정확성만 개선. 각주로 HKCU/HKLM 구분 명시 (2) 3.1 절에 특징 선택의 실증 근거 추가(Barr-Smith et al. IEEE S&P 2021, 3,180 만 샘플 — 레지스트리 변경·정찰·지속성은 악성에서 유의하게 빈번, 프록시 실행은 정상·악성 공통이라 판별력 낮음) (3) 1A.3 절에 은밀성·포착난이도 상관 근거 추가(APT 의 LotL 사용률 26.26% vs 일반 9.41%) 및 샌드박스 수집 편향 명시

- v1.9 (2026-09-16): 13A 절 신설 — 모델 복잡도 스윙을 **탐색적 부가 분석**으로 추가. (1) 확증적 가설(H1~H5)에 추가하지 않고 탐색적으로 명시 선언하여 8 장 다중비교 보정 부담 회피 (2) Phase 6 경량화(처방)와 13A(관계 탐색)의 성격·발동조건·평가데이터를 표로 구분, H5 와의 충돌 방지 (3) Validation 만 사용하도록 제한하여 9 장 Test 보호 원칙 유지 (4) 스윙 단계 (RF 5 단계·MLP 4 단계)를 사전 고정, 결과를 보고 단계 조정 금지 (5) 우선순위 최하 및 생략 시 처리 규칙 명시. 13 장 Phase 표에 6A 행 추가
- v2.0 (2026-09-18): **주실험 데이터셋 확정** — 11.1 절 사전 규칙에 따라 기한(2026-09-18) 내 BCCC 승인 회신이 없어 CIC-MalMem-2022 로 자동 전환. 교차검증 데이터셋(DMBD 2025)은 변경 없음. 14 장 기록 완료
- v2.1 (2026-09-18): **주평가지표 확정** — (1) 8 장 주지표를 F1 → **MCC** 로 교체, 사유 및 반론(Holzmann & Klar) 함께 명시 (2) 보고 지표 세트를 MCC·F1·Precision·Recall·PR-AUC + 혼동행렬로 확대하되 **기술적 보고로 규정하여 다중비교 보정 대상에서 제외** (3) 8.1 절 신설 — 혼동행렬은 "Validation MCC 최고 모델"이라는 **사전 고정 규칙**으로 선정(사후 선택 방지), 시드 5 회 **평균 행렬** 제시, 시드별 원본은 부록 (4) 임계값 조정 시 부트스트랩 CI 병기 및 불안정 시 0.5 회귀 규칙 추가 (5) MCC 교체에 따라 4.2 절 BO 목적함수·10.2 절 허용한도(절대 0.05)·12 장 미수렴 기준(절대 0.20)·13A 절 스윙 지표·H1 서술 연쇄 수정 (6) H4 에 **PR-AUC 는 유병률 의존이므로 데이터셋 간 비교 불가** 주의 추가
- v2.2 (2026-09-18): 비용 가중 관련 정리 — (1) 8 장에 **등가중 가정의 명시적 선언** 추가(MCC·Youden's J·임계값 0.5 에 공통으로 깔린 전제임을 밝히고, 4.3 절 Class Weight 는 불균형 보정이지만 비용 가중이 아님을 구분) (2) **1A.4 절 신설** — 비용 민감 평가 미수행을 명시적 한계로 선언. 비용비를 정할 근거 부재(조직별 상이, 경보 피로 문제)와 Youden's J 비용비의 유병률 의존성을 사유로 기록하고, 향후 연구 과제 및 실무 적용 시 재설정 필요성을 보고 의무로 규정
- v2.3 (2026-09-18): 외부 검토 의견 9 건 반영 — (1) **10.4 절 신설**: H5 를 "선택적 vs 일괄"의 비열등성+우위 이중 검정으로 재구성, δ 사전 고정, 판정불가 규칙 (2) **MCC 개선 기준을 절대차(0.05)로 변경**, 상대 변화율 폐기 (3) **3.3.1 절 신설**: 감염시점 정보에 대한 이중 설정(A 주/B 보조), H1~H5 는 A 에서만 검정 (4) RF 300 을 "본 연구 고정값"으로 표현 정정 (라이브러리 기본값은 100) (5) **5.0 절 신설**: MIA target model 정의 (6) **1.1 절 신설**: H1 을 확증적 가설에서 제외, 상관분석 미수행·반례 판정으로 전환 (7) **6.4 절 신설**: permutation importance 를 Validation/MCC/n_repeats=10 으로 고정, MDI·TreeSHAP 배제 (8) 4.3 절 불균형 처리를 택일 우선순위 체인으로 명확화 (9) 중복제거를 Spearman·결정론적 제거 규칙으로 구체화. 스택킹 베이스 상관 측정은 미추가 결정
- v2.4 (2026-09-18): 2 차 외부 검토 9 건 반영 — (1) **H5 비열등성 부등식을 지표 방향별로 분리**(수학적 오류 수정) (2) **5.4 절 신설**: $AUC_{adv} = \max(AUC, 1-AUC)$ 도입 및 전 판정 규칙에 적용 (3) "**CI 폭 > 2 δ** " 판정불가 규칙 폐기, $\pm\delta$ 경계 교차 여부에 의한 3 분 판정으로 대체(수학적 오류 수정) (4) **10.3 절**: Phase 6 출발 모델을 **Model A** 로 고정 (5) **6.4 절**: H2 분석 단위를 **최종 입력 특징 컬럼**으로 고정, 교란 민감도 S_i 부호 정의 (6) 본문의 BCCC 잔재를 CIC-MalMem-2022 로 통일 (7) nested CV 용어를 "Train 내부 3-fold CV"로 정정 (8) MCC·Youden's J·0.5 의 비용 관련 성격을 표로 분리 (9) 12 장 B·C 규칙이 Phase 6 진입과 무관함을 명시
- v2.5 (2026-09-18): **Phase 1 데이터 구조 확인 결과 반영** — (1) 3.2 절 재확정: 분석 단위를 "**1 실행**"에서 "**1 메모리 덤프(1 행)**"로 변경, 3.3·3.3.1 절 폐기. 정상 샘플에 실행 ID 가 없어 악성만 집계하면 std=0 이 클래스를 완벽 판별하는 치명적 누수가 발생하기 때문 (2) **3.2.1 절 신설** — 정상 그룹 구조 복원 불가 검정 근거 기록 (3) **2.1 절 비대칭 그룹 분할** — 악성은 실행+family, 정상은 행 단위 (4) **3.3.2 절** 중복 제거를 원 특징 55 개 기준으로 이관, 상수 3 개 사전 제거 (5) 조건부 규칙 확정: 불균형 미적용·MIA 옵션 A·shadow model 1 순위 (6) 6.2~6.3 절 난이도 분류가 실제 특징과 불일치함을 확인, Phase 2 재작성 과제로 등록
- v2.6 (2026-09-18): **Phase 2 완료 — 주실험 데이터셋 교체 및 특징 확정** — (1) **11 장 전면 재작성**: CIC-MalMem-2022 에서 환경 지문 발견(깊이 1 트리 99.65%)으로 주실험을 **DMBD 2025** 로 교체, CIC-MalMem 은 11.3 절 벤치마크 타당성 사례연구로 전환 (2) **H4 를 코호트 간 재현(2017 vs 2024)으로 재정의** (3) 3.2 절 분석 단위를 **실행(experiment)**으로 복원 — DMBD 는 양쪽 클래스 모두 실행 ID 보유 (4) **3.3.2 절 특징 14 개 확정**, detonation·dur_after_detonation_s 제외, **발생을 정규화 폐기**(duration 중앙값 1.36 초로 불안정) (5) **6.3 절 난이도 분류 전면 재작성**(쉬움 9/어려움 4/제외 1), H2 의 n=9 (6)

11.2.1 절: 공식 분할 보존하되 연도-라벨 교란 명시 + **8 장 코호트별 분리 보고 의무** (7) 조건 재판정: MIA 옵션 B, Class Weight 적용 (8) 1A.2 절 관측 창 서술 정정

- v2.7 (2026-09-19): **Phase 3 완료 — 모델 4 종 구축** — (1) **BO 를 GP-EI 로 대체**(hyperopt 미설치), 탐색공간 불변 (2) **4.3 절 Class Weight 판정 정정** — Train 이 50:50 이므로 미적용 (3) MLP 를 sklearn 기본값 (100,) 미튜닝으로 확정, A ↔ D 대칭성 확보 (4) 스택킹 베이스를 HistGradientBoosting 으로 교체 (5) max_features 상한 [1,12] 확정 (6) **H2 분석단위 n=9 → 7** — 중복 제거로 교란 대상 2 개 탈락, 규칙은 사후 변경하지 않음 (7) **11.2.2 절 신설** — Train(50%) ↔ Test(78.8%) 사전확률 이동 발견
- v2.8 (2026-09-19): **H5 평가 무대 재설계** — (1) **2.1 절 분할 변경:** 공식 train 을 Train 60% / Validation 20% / **H5-Test 20%**로 3 분할 (2) **9 장 전면 개정:** 평가셋 4 종의 보호 수준·사용 시점 표로 명시, "선택과 검증의 분리" 원칙 명문화 (3) **10.3~10.4 절:** H5 판정을 H5-Test 로 이동, 공식 Test 는 시간적 일반화 보고 전용으로 용도 한정 (4) 8 장 코호트별 보고 의무를 공식 Test 에 한정. ⚠ 분할 변경에 따라 **Phase 3 재실행 필요**
- v2.9 (2026-09-20): **Phase 3 재실행 완료** — (1) 새 분할(Train 24,000/Val 8,000/H5-Test 8,000)로 BO 재탐색 포함 전 과정 재수행, 봉인 해시 기록 (2) 4.2 절에 BO 최적 하이퍼파라미터 기록 (3) **스택킹 효과 판정이 "하락 확정"에서 "유의미한 차이 발견 못함"으로 변경** — 효과 크기가 아닌 검정력 변화에 기인 (4) **모델 C 임계값을 0.5 고정으로 회귀** — 부트스트랩 CI 폭 0.262 로 8 장 불안정 기준 초과
- v3.0 (2026-09-20): **Phase 4 완료 — 3 대 진단 수행** — (1) **리소스:** batch 10/100/1000 지연·처리량·메모리 측정, §10.1 기준배치를 **batch=10** 으로 확정 (2) **MIA:** shadow model 5 개·연도 매칭 적용, A 0.5720 / B 0.5259 / C 0.5230 검출, **D 0.5001 미검출**(CI 가 0.5 포함) (3) **교란 민감도:** 7 개 특징 × 5 단계, 최대 flip rate 6.45%, 무효 변형 0 건 (4) **H2:** 네 모델 모두 양의 상관($p +0.536 \sim +0.893$), $n=7$ 로 경향 관찰 수준 (5) **13.1 절 신설** — "중요도"와 "비례 감소 민감도"의 개념적 분리 발견 (net_connect 사례)
- v3.1 (2026-09-20): **Phase 5 종결 — H4 폐기** — (1) Train+Val 의 2024 코호트에 악성 0 건으로 원안 수행 불가. 대안 4 종을 검토했으나 검정력·교란·독립성 사유로 모두 기각 (2) §11.2.3 신설: 폐기 근거와 함께 **연도-라벨 교란이 데이터셋 전면 존재함**을 정량 기록(연도만으로 AUC 0.9070) (3) §11.2.1 의 교란 서술을 공식 test 한정에서 데이터셋 전체로 확대 (4) 확증적 가설이 **H2·H3·H5 세 개**로 축소, 8 장 다중비교 대상 갱신 (5) 12 장에 재현 측 부재 시 처리 규칙 추가
- v3.2 (2026-09-20): **§11.2.4 신설 — 간접 교란 검증** — (1) 행위 특징이 연도 정보를 직접 함유함을 확인(연도 회귀 $R^2=0.639$, "2017?" AUC=0.943. 라벨 고정 시에도 악성내부 $R^2=0.578$) (2) 영향 크기를 통제 설계로 분리 — 표본 수 효과 -0.0392 vs 교란 제거 효과 -0.0282 (3) **연도단독 AUC 를 0.5000 으로 만든 조건에서도 MCC 0.7788 / AUC 0.9500 유지** → 모델이 실제 행위를 학습한다는 근거 (4) 교란 기여 약 0.03 MCC 를 Phase 6 개선효과 해석 시 병기하도록 보고 의무 규정
- v3.3 (2026-09-21): **Phase 6 착수 준비** — (1) **§10.1 발동 기준 복원** — v1.3 의 크기→유의성 치환 오류를 정정(프라이버시 CI 하한>0.6, 강건성 CI 하한>30%). 발견 경위를 투명성 차원에서 기록. 복원 결과 모델 A 는 **리소스 축만 발동** (2) **§7.1 신설** — 상시 구동 관점 확장 측정(직렬화 크기, $p_{50 \sim p_{99}}$ 꼬리지연, 집계비용) 및 업계 실측치 대조. 집계비용이 하한으로 작용해 추론 최적화의 한계 확인 (3) **§8 에 리소스 개선 성공 기준 추가** — batch=10 기준 20% 상대 감소
- v3.4 (2026-09-21): **Phase 6 실행 명세 확정 — §10.3A 신설** — H5-Test 봉인 해제 전 7 개 항목 고정: ① 리소스 성공기준(20% 상대감소) ② 탐색예산 축별 10 회 + §4.2 총량맞춤 조항 폐기 ②-1 일괄개선 허용한도 필터 미적용 ③ **교란학습 누수 수정** (Train 에서 생성) ④ 프라이버시 선택 두 단계 분리 ⑤ **정규화 파라미터 min_samples_leaf ∈ {2,5,10}** ⑥ H5 목표축/부작용축 명시 ⑦ 경량화 후보 10 개
- v3.5 (본 문서, 2026-09-21): **Phase 6 완료** — (1) **10A.1 H5 기각:** 목표축 비열등·MCC 우위이나 MIA 열등으로 지지 조건 불충족 (2) **10A.2 H5 설계 문제**를 사후 식별해 교훈으로 기록(판정 불변) (3) **10A.3 교란학습 설계 결함** — 악성만 증강해 사전확률 50% → 58.3% 이동, 2024 코호트 AUC 차이 +0.0045 로 탐지율 우위가 경계 이동 착시임을 정량 확인 (4) **10A.4 공식 Test 코호트별 보고** — 전 모델 시간 격차 +0.06~+0.13 (5) **13.2 B 해석 정정** — "일반화 희생"이 아닌 "보수적 경계 형성"

A.3.3 §10.1 정정 상자

§10.1 발동 기준 복원 (2026-09-21) ⚠ v1.3 에서 §10.1 을 CI 기반으로 개편할 때 **크기 기준을 귀무가설 기준으로 잘못 치환한 오류**를 정정한다. | 축 | v1.2 (데이터 존재 이전 설정) | v1.3~v3.2 (오류) | **v3.3 (복원)** | ---|---|---|---| 프라이버시 | MIA AUC > 0.6 | AUC_adv CI 하한 > 0.5 | **AUC_adv CI 하한 > 0.6** || 강건성 | flip rate > 30% | flip 증가폭 CI 하한 > 0 | **flip rate CI 하한 > 30%** || 리소스 | > 1ms | > 1ms | > 1ms (불변) | **오류의 성격:** "CI 하한 > 0"은 **효과가 조금이라도 존재하는가**(통계적 유의성)를 묻고, "> 30%"는 **효과가 문제될 만큼 큰가**(실질적 크기)를 묻는다. v1.2 의 의도는 **실질적으로 문제가 되는 취약점에만 개선안을 적용하는** 것이었으나, v1.3 변환 후에는 3,626 건 중 3 건(0.08%)만 뒤집히는 reg_write 도 "취약점"으로 판정되었다. 복원은 v1.2 의 크기 기준에 v1.3 의 CI 엄밀성을 결합한 형태다. **발견 경위 (투명성 기록):** 이 오류는 Phase 6 착수 시 모델 A 가 세 축 모두에서 개선 대상으로 판정되어 **선택적 개선과 일괄 개선이 동일해지는(H5 퇴화)** 현상을 조사하다 발견되었다. 즉 결과를 보고 발견한 것이다. 다만 다음 세 가지 이유로 사후 조작이 아니라 **오류 정정**으로 판단한다. 1. 복원한 값(0.6, 30%)은 **데이터가 존재하기 전(v1.2)에 설정된 값**이며, 현재 결과를 보고 새로 고른 숫자가 아니다 2. **H5-Test 는 봉인 상태**이므로 H5 의 결론은 아직 누구도 알지 못한다 3. 복원 사유는 결과 변경이 아니라 v1.3 변환의 **개념적 오류**(유의성과 크기의 혼동)다 **복원 후 모델 A 의 판정:** 프라이버시 ❌(CI 하한 0.5544) / 강건성 ❌(최대 CI 하한 0.0454) / 리소스 ✅(1.2209ms) → **선택적 개선 = 경량화만**

A.4 정정 대조표 — 프로토콜의 기록과 원고의 서술이 다른 곳

원고를 쓰며 데이터·산출물·원문을 다시 확인해 정정한 내용이다. **원고의 서술이 최신이다.** 프로토콜 위치는 보충 자료 S1 의 절 번호다.

A.4.1 수치와 해석

#	프로토콜 위치	프로토콜의 기록	원고의 서술	원고
1	§11.3	CIC-MalMem-2022 에서 깊이 3 결정트리의 정확도 99.84%	99.89%. 99.84%는 같은 실행의 덤프를 묶지 않은 분할의 값이며, 실행 단위로 묶은 교차검증으로 다시 계산했다. 깊이 1(99.65%)은 분할 방식과 거의 무관했다	4.1 표 5
2	§11.1, A.3.1(2026-09-18 "CIC-MalMem artifact 발견"), A.3.2(v2.6)	서비스 수 차이를 "VM 환경 상태", "환경 지문"으로 해석	정상과 악성은 같은 가상 머신에서 수집되었다. 서비스 수 차이가 악성 행위의 흔적인지 수집 구성의 차이인지는 데이터만으로 가릴 수 없다	4.1.1
3	§11.1	DMBD 2025 에 깊이 1·3 결정트리를 적용해 "artifact 부재 확인"	깊이 1 점검은 모델 입력에 있는 특징만 볼 수 있어, 입력에 없는 수집 연도의 교란을 잡지 못했다. DMBD 2025 에는 이 교란이 있다	4.1.2, 5.2
4	§13.2, A.3.1(2026-09-21 "B 해석 정정"), A.3.2(v3.5)	모델 B 의 낮은 탐지율을 균형 데이터에서 최적화된 보수적 판단 경계로 설명하고, B 의 악성 평균 확률을 "최저"로 기록	균형 데이터로 학습했다는 설명은 논리 오류다. 탐지율은 시험 분할의 클래스 비율에 좌우되지 않으며, 모델 A·C 도 같은 데이터로 학습했다. 원인은 B 의 하이퍼파라미터이며 어느 설정인지는 분리하지 않았다. 악성 평균 확률은 랜덤 포레스트 계열 중 최저다(모델 D 가 더 낮다)	4.4.3
5	§10A.4	2024 년 악성 코호트의 탐지율이 "약 80%로 하락"	랜덤 포레스트 계열 0.795~0.881(범위로 서술)	4.4.1
6	§7.1 (3)·(4), A.3.1(2026-09-21 "리소스 개선 성공 기준 확정"), A.3.2(v3.3)	집계 비용 0.4409ms 가 추론 최적화의 하한. 업계 실측치와 대조해 네 모델 모두 CPU 1% 미만	집계 비용 값은 실험 산출물에 남아 있지 않아 원고에서 쓰지 않았다. 업계 수치는 근거 자료(업체 보고서 등)를 원문으로 확인하지 않아 쓰지 않았다	5.3, 6.2.2

A.4.2 프로토콜에 남은 옛 설정값

#	프로토콜 위치	프로토콜의 기록	실제로 쓴 값	원고
7	§4.2	scikit-learn 1.9.1	1.8.0 (1.9.1 은 초기 로컬 점검 환경)	3.5, 부록 B
8	§3.4, §4.3	처리 순서에 Class Weight 적용	학습 분할이 50:50 이라 적용하지 않음(A.3.2 v2.7 에도 기록)	3.5
9	§2.1, §4.2	베이지안 최적화의 교차검증에서 family 비중복 유지	DMBD 2025 에는 family 라벨이 없어 학습 분할 안에서 중화 3 겹	3.5

#	프로토콜 위치	프로토콜의 기록	실제로 쓴 값	원고
10	§4.2	일괄 개선이 선택적 개선과 같은 총 탐색 예산을 씀	개선 때마다 10 회 (§10.3A 에서 해당 조항 폐기)	3.2, 3.7
11	§1	H2 분석 단위 $n \approx 12$	중복 특징 제거 후 $n=7$ (A.3.2 v2.7)	3.1, 4.2.3
12	§4.2	MLP 조기 종료를 Validation loss 정체로 판단	scikit-learn 기본 방식 — 학습 분할의 10%를 내부 검증용으로 떼어 그 점수로 판단	3.5

A.4.3 명세와 실제 수행이 다른 곳

#	프로토콜 위치	명세	실제 수행	원고
13	§8	H2·H3·H5 에 BH 다중비교 보정 적용	실험 중에는 계산하지 않았다. 원고 작성 중 H2 에 적용했으며(보정 후 모델 D 만 유의, 결론 불변), H3·H5 의 신뢰구간에는 보정을 적용하지 않았다	4.2.3, 5.2, 6.2.3
14	§6.3	duration_s 는 증가 방향의 조작만 유효	교란은 일곱 특징 모두 감소 방향으로 가했다	3.6.3, 5.2, 6.2.2
15	§5	멤버십 추론 표본을 공격 학습·임계값 보정(50%), 개선안 선택(25%), 최종 감사(25%)로 분할	공격 모델은 shadow 모델의 출력으로 학습했으므로 첫 50%는 쓰지 않았다	3.6.2
16	§8.1	시드별 혼동행렬 원본을 부록에 제시	부록에 실지 않았다. 원고는 시드 평균과 신뢰구간을 보고한다	—

A.4.4 용어와 외부 자료

#	프로토콜 위치	프로토콜의 기록	원고의 처리
17	전반	"사전등록"	"사전 명세". 공개 저장소에 시점을 남기는 등록이 아니므로 사전 등록이라 부르지 않는다(3.2 절)
18	§1A.2, A.3.2(v1.7·v1.8), §1A.4, §7.1 (4)	위험 시간 척도의 수치, 레지스트리 조작의 근거, 비용 민감 평가의 근거, 업계 실측치 등 외부 자료 인용	원고는 이 자료들을 근거로 쓰지 않았으며, 원문 확인도 거치지 않았다. 원고가 인용한 문헌은 모두 원문으로 확인했다

부록 B. 구현 세부

B.1 실행 환경

항목	값
Python	3.12
scikit-learn	1.8.0
numpy / pandas / scipy	2.4.4 / 3.0.2 / 1.17.1
psutil	7.2.2
CPU / 메모리	1 코어 / 3.9GB
병렬 처리	자원 측정은 단일 스레드($n_jobs=1$)로 고정

hyperopt, optuna, xgboost, lightgbm 은 실행 환경에 설치되어 있지 않았다. 이 때문에 베이지안 최적화를 가우시안 과정과 기대 개선량으로 직접 구현했고 (B.5), 스택킹의 부스팅 기반 모델은 scikit-learn 의 HistGradientBoostingClassifier 를 썼다(A.3.2 v2.7).

출처: 산출물 README "환경", `phase4/results/env.json`

B.2 데이터와 분할

데이터. DMBD 2025 의 실행 단위 집계본(64,747 개 실행)을 사용했다.

분할.

분할	크기	용도	봉인 해시
학습	24,000	모델 학습	—
검증	8,000	진단, 개선안 선택	—
H5 시험	8,000	H5 판정 (한 번만 열람)	47254fd15bb1f192
공식 시험	24,747	시간적 일반화 보고 (한 번만 열람)	c63d8ca03e7a4480

분할 인덱스는 원본 CSV 의 행 번호로 저장했다(tr_idx.npy, va_idx.npy, h5_idx.npy, offtest_idx.npy).

특징. 처음 14 개 특징 가운데 스피어만 상관계수의 절댓값이 0.95 를 넘는 쌍에서 열 순서상 뒤의 특징을 제거했다.

제거한 특징	짜을 이론 특징	상관계수
n_uniq_child	n_events	0.9829
n_uniq_cguid	n_events	1.0000

최종 특징 12 개: file_create, image_load, net_connect, process_create, process_term, reg_create_key, reg_delete_key, reg_delete_value, reg_write, n_events, duration_s, n_uniq_parent

출처: `phase3/results/featureset.json`, `phase3/scripts/prep.py`

B.3 난수 시드

용도	시드
데이터 분할	42
모델 학습 (5 회 반복)	42, 7, 123, 2024, 777
베이지안 최적화와 그 교차검증	42
스태킹의 표본 외 예측(OOF) 교차검증	42
멤버십 추론의 shadow 모델	1000 + k (k = 0, ..., 4)

베이지안 최적화의 중간 상태는 난수 상태까지 함께 저장해(bo_state.pkl), 실행을 중단했다가 재개해도 결과가 같다.

출처: 산출물 README "재현성 보장 장치", `phase3/scripts/run\_models.py`, `phase4/scripts/mia.py`

B.4 모델 설정

모델	설정
A 랜덤 포레스트	트리 300 개(본 연구의 고정값. 라이브러리 기본값은 100 개), 나머지는 scikit-learn 기본값
B 랜덤 포레스트 + 베이지안 최적화	B.5 의 최적 하이퍼파라미터: 트리 54 개, 최대 깊이 50, max_features=2, min_samples_split=11, min_samples_leaf=1, 분할 기준 지니 불순도
C 스태킹	기반 모델: 모델 B 와 같은 설정의 랜덤 포레스트 3 개(시드 s, s+1, s+2) + HistGradientBoostingClassifier(기본값, 시드 s). 메타 모델: 로지스틱 회귀(max_iter=1000). 메타 모델은 학습 분할에 대한 층화 5 겹 표본 외 예측 확률로 학습하고, 기반 모델은 학습 분할 전체로 다시 학습
D 다층 퍼셉트론	은닉층 (100,)(scikit-learn 기본값), max_iter=200, 조기 종료(학습 분할의 10%를 내부 검증용으로 떼어 그 점수가 10 회 연속 나아지지 않으면 중단). 입력은 학습 분할로 적합한 표준화

모든 모델은 임계값 0.5 로 판정했다.

출처: `phase3/scripts/run\_models.py`, `phase3/results/bo\_result.json`

B.5 베이지안 최적화

탐색 공간.

하이퍼파라미터	범위
n_estimators	정수 10~200
max_depth	정수 5~50
max_features	정수 1~12 (최종 특징 수)
min_samples_split	정수 2~11
min_samples_leaf	정수 1~11
criterion	{gini, entropy}

절차.

항목	설정
목적 함수	학습 분할 안에서의 총화 3 겹 교차검증 MCC 평균
시도 횟수	무작위 초기 10 회 + 가우시안 과정 기반 20 회 = 30 회
대리 모델	가우시안 과정. 커널은 상수 $\times$ Matérn($\nu=2.5$, 차원별 길이 척도) + 백색 잡음($1e-4$). 목적 함수 값 정규화, 커널 매개변수 최적화 재시작 2 회
획득 함수	기대 개선량($\xi=0.01$). 무작위 후보 2,000 개 가운데 최댓값을 다음 시도로 선택
결과	교차검증 MCC 최댓값 0.8285 (30 회 가운데 18 번째 시도)

출처: `phase3/scripts/run\_bo.py`, `phase3/scripts/gpbo.py`, `phase3/results/bo\_result.json`

B.6 진단 설정

B.6.1 멤버십 추론

항목	설정
회원·비회원	회원은 학습 분할, 비회원은 검증 분할에서 뽑고, 연도별로 두 집합의 개수를 같게 맞추었다
역할 분리	공격 학습 50%, 개선안 선택 25%, 최종 감사 25%. 공격 모델은 shadow 모델의 출력으로 학습했으므로 공격 학습 묶은 쓰지 않았다(A.4 #15)
최종 감사 집합	회원 1,999 개, 비회원 1,999 개(고정, mia_audit_mem.npy, mia_audit_non.npy)
shadow 모델	5 개. 각각 학습 분할에서 무작위로 고른 12,000 개로 대상 모델과 같은 설정을 학습하고, 나머지 12,000 개를 비회원으로 삼았다
공격 모델	로지스틱 회귀(max_iter=1000). 입력은 예측 확률의 최댓값, 정답 클래스의 확률, 예측 분포의 엔트로피
지표	방향 보정 AUC(max(AUC, 1-AUC)), 오탐률 1%에서의 참양성률

출처: `phase4/scripts/mia.py`, `phase4/results/mia.json`

B.6.2 특징 교란

항목	설정
교란 대상 특징	net_connect, file_create, reg_write, reg_create_key, reg_delete_key, reg_delete_value, duration_s (7 개)
교란 크기	5%, 10%, 15%, 20%, 30% 감소
부수 효과 반영	발생 횟수 특징을 바꾸면 그 합인 n_events 를 다시 계산
무효 처리	감소시킨 값이 음수가 되거나 학습 분할의 관측 범위를 벗어나면 무효
순열 중요도	검증 분할, 점수 MCC, 반복 10 회

출처: `phase4/scripts/perturb.py`

B.6.3 자원

항목	설정
배치 크기	10, 100, 1,000
반복	배치 크기마다 20 회
시간 측정	time.perf_counter. 샘플당 지연은 배치 시간을 배치 크기로 나눈 값. 개선 발동 기준은 배치 10

항목	설정
메모리 측정	tracemalloc(Python 할당)과 psutil 의 RSS(프로세스 물리 메모리)를 함께 기록
직렬화 크기 (탐색적)	A 110.09MB, C 31.79MB, B 10.53MB, D 0.04MB

출처: `phase4/scripts/bench\_resource.py`, `phase4/scripts/resource\_extended.py`, `phase4/results/resource\_extended.json`

B.7 개선 전략의 후보와 선택

단계	적용	후보	선택 기준	선택값
경량화	선택적·일괄·공통	트리 수 20, 29, 38, 47, 56, 64, 73, 82, 91, 100	지연 감소, 허용 한도	20 (검증 MCC 0.8186)
정규화	일괄	min_samples_leaf 2, 5, 10	회원·비회원 확산도 격차	10 (격차 0.0048, 검증 MCC 0.8072)
출력 이산화	일괄	예측 확률을 소수점 첫째·둘째 자리로 반올림	개선안 선택용 집합의 멤버십 추론 AUC	첫째 자리 (0.5223, 둘째 자리 0.5229)
교란 학습	일괄	학습 분할 악성 샘플 수(12,000)의 10%, 20%, 30%, 40%, 50% 만큼 교란 샘플 추가	검증 분할의 최대 flip rate 가 가장 낮은 것, 같으면 검증 MCC 가 높은 것	40% (4,800 개)

교란 학습 샘플의 출처. 학습 분할의 악성 샘플을 B.6.2 의 방식으로 20% 교란해 판정이 뒤바뀐 샘플은 575 개였다. 추가 샘플은 이 575 개에서 복원 추출했으므로, 모든 후보가 같은 샘플을 중복해서 썼다.

증강 비율	10%	20%	30%	40% (선택)	50%
추가 샘플 수	1,200	2,400	3,600	4,800	6,000
575 개 대비 배수	2.09	4.17	6.26	8.35	10.43

선택된 40%에서는 학습 데이터의 악성 비율이 50%에서 $(12,000 + 4,800) / (24,000 + 4,800) = 58.3\%$ 로 옮겨 갔다(5.2 절, 6.2.3 절).

출처: `phase6/scripts/step1\_lightweight.py`, `step23.py`, `step4\_perturb.py` 및 각 결과 파일

B.8 스크립트와 결과 파일의 대응

단계	스크립트	결과	원고
데이터 준비·분할·중복 제거	phase3/scripts/prep.py	featureset.json, indices/*.npz	3.3, 3.4
베이지안 최적화	phase3/scripts/run_bo.py, gpbo.py	bo_result.json, bo_state.pkl	3.5
모델 학습·검증 성능	phase3/scripts/run_models.py, summarize.py	results_all.json, probs/	4.2.1
자원	phase4/scripts/bench_resource.py, resource_extended.py	resource.json, resource_extended.json	4.2.2
멤버십 추론	phase4/scripts/mia.py	mia.json, mia_audit_*.npz	4.2.2
교란 민감도·순열 중요도	phase4/scripts/perturb.py	perturb.json	4.2.2, 4.2.3
연도 교란	phase4/scripts/year_confound.py, cohort_check.py	year_confound.json, cohort_check.json	4.1.2
경량화	phase6/scripts/step1_lightweight.py	step1_lightweight.json	4.3
정규화·이산화	phase6/scripts/step23.py	step23.json	4.3
교란 학습	phase6/scripts/step4_perturb.py	step4_perturb.json	4.3
H5 판정	phase6/scripts/h5_eval_part1.py, h5_eval_part2_mia.py	h5_eval_part1.json, h5_eval_part2_mia.json	4.3
공식 시험 분할	phase6/scripts/official_test.py	official_test_cohort.json	4.4

스크립트는 원래 실행 환경의 경로를 쓰므로, 다른 환경에서 다시 실행하려면 경로를 바꿔야 한다.